

Pipeline Quantitatif de Pair Trading Avancé

Contents

1	Introduction	4
1.1	Objectif du projet	4
2	Imports et Étude des données	5
2.1	Analyse des corrélations	10
2.2	Observation clé	12
2.3	Test de cointégration	12
2.4	Paire retenue	13
2.5	Analyse multi-périodes	14
2.6	Analyse de stationnarité	15
2.7	Étude du spread SHW / HD	17
2.8	Étude du Z-score SHW / HD	18
3	Stratégie de Pair Trading	19
3.1	Estimation du hedge ratio par régression OLS	19
3.2	Analyse du Spread et du Z-score	20
3.3	Génération des signaux de trading	21
3.4	Backtest de la stratégie	22
4	Coûts de transaction	23
5	Optimisation des seuils du Z-score	25
5.1	Sélection de la meilleure stratégie	25
5.2	Backtest optimisé	26
5.3	Backtest de la stratégie optimisée	26
5.4	Analyse du Z-score optimisé et sauvegarde des résultats	27
6	Benchmark : Pair Trading vs Buy & Hold	29
6.1	Objectif	29
6.2	Résultats	29
6.3	Analyse des résultats	29
6.4	Nuance méthodologique	30
6.5	Conclusion	30
7	Prédiction de Convergence (Machine Learning Classifieur)	31

8 Prédiction du rendement à J+1 par régression	33
8.1 Objectif	33
8.2 Méthodologie	33
8.3 Résultats	34
8.4 Interprétation	34
8.5 Pourquoi ce résultat est attendu	35
8.6 Utilité dans le pipeline	35
9 Modèle de Machine Learning sans Data Leakage	36
9.1 Entraînement du classifieur sans fuite d'information	36
9.2 Split temporel	36
9.3 Validation croisée temporelle	37
9.4 Performance du classifieur	37
9.5 Rapport de classification	37
9.6 Importance des variables	37
9.7 Régression sans fuite d'information	38
9.8 Interprétation	38
10 XGBoost Classification	39
10.1 Entraînement du modèle XGBoost	39
10.2 Performances du modèle	39
10.3 Importance des variables	40
10.4 Comparaison Random Forest vs XGBoost	40
11 Deep Learning — LSTM	40
11.1 LSTM Classifieur	41
11.1.1 Architecture et paramètres	41
11.1.2 Courbe d'apprentissage	41
11.1.3 Performances	41
11.1.4 Probabilités de convergence prédites	42
11.2 LSTM Régresseur	42
11.2.1 Objectif	42
11.2.2 Convergence de l'entraînement	42
11.2.3 Performances	42
11.2.4 Prédictions vs rendements réels	43
11.3 Synthèse	43
12 Analyse de Sentiment NLP	44
12.1 Principe de l'analyse lexicale	44
12.2 Données utilisées	44
12.3 Résultats obtenus	45
12.4 Interprétation et utilisation dans le pipeline	45
12.5 Limites de l'approche	45
13 Filtre Machine Learning	46
13.1 Comparaison : stratégie brute vs stratégie filtrée par Machine Learning	47
13.2 Performance de la stratégie filtrée par Machine Learning	47
13.3 Comparaison des résultats	48

14 Méta-Modèle	50
14.1 Entraînement	50
14.2 Performance du méta-modèle	50
14.3 Probabilité et recommandation finale	51
14.4 Tableau de décision final	51
14.5 Coefficients du méta-modèle	52
14.6 Synthèse	53
15 Conclusion générale	53
15.1 Synthèse des Résultats Économiques et Modélisations	53
15.2 Perspectives d'Amélioration	54

1 Introduction

Les marchés financiers présentent régulièrement des déséquilibres temporaires entre des actifs ayant des comportements économiques similaires. Le *pair trading* est une stratégie quantitative qui cherche à exploiter ces écarts de prix à court terme à travers une approche de *mean reversion* (retour à la moyenne).

Le principe du pair trading consiste à sélectionner deux actifs fortement corrélés et cointégrés, puis à analyser l'évolution de leur spread, c'est-à-dire l'écart de prix entre ces deux actifs. Lorsque cet écart devient anormalement élevé ou faible par rapport à sa moyenne historique, la stratégie prend des positions opposées sur les deux actifs dans l'hypothèse que le spread reviendra progressivement vers son niveau d'équilibre.

Cette approche présente plusieurs avantages. Tout d'abord, elle permet de construire une stratégie dite *market neutral*, c'est-à-dire relativement indépendante de la direction globale du marché. En prenant simultanément une position acheteuse sur un actif et vendeuse sur un autre, l'exposition au risque systématique peut être réduite.

L'objectif principal de ce projet est de développer une stratégie complète de pair trading appliquée aux actions SHW (*Sherwin-Williams*) et HD (*Home Depot*). Le projet combine des méthodes statistiques et des techniques de Machine Learning afin d'améliorer la détection et la sélection des opportunités de trading.

Dans un premier temps, l'étude porte sur l'analyse de la corrélation et de la cointégration entre les deux actifs afin de vérifier l'existence d'une relation de long terme stable. Ensuite, un spread est construit à l'aide d'une régression OLS et des signaux de trading sont générés grâce au Z-score du spread.

Une phase de backtest permet ensuite d'évaluer la rentabilité et le profil de risque de la stratégie. Enfin, un modèle de Machine Learning est intégré afin de filtrer les signaux et d'améliorer la qualité des décisions de trading.

Ce projet illustre ainsi l'intérêt d'une approche hybride combinant finance quantitative, statistiques et intelligence artificielle dans le cadre du développement de stratégies algorithmiques.

Cette partie du projet correspond au fichier `main.py`, qui constitue le point d'entrée du système.

Son rôle est d'orchestrer l'ensemble du pipeline quantitatif de pair trading en exécutant successivement les différents modules développés.

Le système repose sur une architecture modulaire permettant de séparer clairement les étapes de traitement, d'analyse et de décision.

1.1 Objectif du projet

L'objectif principal est de construire une stratégie de pair trading complète capable de :

- identifier des paires d'actifs statistiquement liées
- exploiter les déséquilibres temporaires via le spread
- améliorer la qualité des signaux grâce au Machine Learning
- intégrer des informations qualitatives issues du sentiment de marché
- optimiser le rendement ajusté du risque

2 Imports et Étude des données

Récupération des données financières

Les données de marché constituent la base du pipeline de pair trading. Elles sont récupérées à partir d'un univers de 30 actions du S&P 500 défini dans le fichier de configuration.

Les données proviennent de Yahoo Finance via `yfinance`.

- prix ajustés
- rendements journaliers
- période multi-années

Pourquoi les rendements ?

Les rendements sont stationnaires contrairement aux prix :

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}}$$

Cela est essentiel pour :

- corrélation stable
- clustering cohérent
- cointégration fiable

Configuration des données

L'univers d'étude est défini comme suit :

```
TICKERS = [ "AAPL", "AMGN", "AMZN", "AXP", "BA", "CAT", "CRM",  
            "CSCO", "CVX", "DIS", "GS", "HD", "HON", "IBM", "JNJ", "JPM",  
            "KO", "MCD", "MMM", "MRK", "MSFT", "NKE", "NVDA", "PG", "SHW",  
            "TRV", "UNH", "V", "VZ", "WMT" ]
```

La période d'analyse est définie entre :

```
START_DATE = "2022-01-01"  
END_DATE = "2025-01-01"
```

Ces paramètres permettent de garantir :

- une diversité sectorielle importante
- une couverture temporelle suffisante pour la cointégration
- une robustesse statistique des modèles

Chargement des données

Les données sont téléchargées via la fonction principale du module `data` :

```
prices, returns = download_prices( TICKERS, START_DATE, END_DATE)
```

Cette fonction retourne :

- **prices** : matrice des prix historiques
- **returns** : rendements journaliers calculés à partir des prix

Conclusion de l'étape

Cette étape permet de :

- construire une base de données cohérente multi-actifs
- standardiser les séries temporelles
- préparer les données pour les étapes de clustering et cointégration

Elle constitue la première brique essentielle du pipeline de pair trading.

Aperçus des tables

Date	AAPL	AMGN	AMZN	AXP	BA
2022-01-03	177.94	198.29	170.40	159.12	207.86
2022-01-04	175.68	199.29	167.52	164.23	213.63
2022-01-05	171.01	196.93	164.36	162.48	213.07
2022-01-06	168.15	196.96	163.25	163.97	211.34
2022-01-07	168.32	198.81	162.55	165.37	215.50

Table 1: Extrait des prix historiques

Date	AAPL	AMGN	AMZN	AXP	BA
2022-01-04	-0.0127	0.0051	-0.0169	0.0321	0.0278
2022-01-05	-0.0266	-0.0119	-0.0189	-0.0107	-0.0026
2022-01-06	-0.0167	0.0001	-0.0067	0.0092	-0.0081
2022-01-07	0.0010	0.0094	-0.0043	0.0086	0.0197
2022-01-10	0.0001	0.0136	-0.0066	-0.0037	-0.0287

Table 2: Extrait des rendements journaliers

Statistique	AAPL	AMZN	NVDA	MSFT
Moyenne	0.00059	0.00063	0.00259	0.00049
Ecart-type	0.01707	0.02415	0.03482	0.01737
Min	-0.05868	-0.14049	-0.10005	-0.07716
Max	0.08897	0.13536	0.24370	0.08227

Table 3: Statistiques descriptives des rendements

Clustering

Les actifs sont regroupés selon leur similarité statistique à l'aide de :

- la corrélation des rendements
- un clustering hiérarchique
- une distance seuil (distance threshold)

Pourquoi ça marche ?

Les actifs corrélés partagent :

- mêmes facteurs macro
- mêmes secteurs
- mêmes drivers de marché

```
cluster_df, corr_matrix, linkage_matrix = compute_clusters(  
    returns,  
    DISTANCE_THRESHOLD  
)
```


Résultat du clustering

Ticker	Cluster
JNJ	1
AMGN	1
KO	1
WMT	2
VZ	3
CVX	4
TRV	4
V	5
.....	
AAPL	5

Visualisation du dendrogramme


Le clustering hiérarchique est visualisé à l'aide d'un dendrogramme, permettant d'observer la structure de similarité entre les actifs.

```
plot_dendrogram( linkage_matrix, labels=returns.columns )
```

Visualisation PCA

```
cluster_pca_df = plot_clusters_pca( returns, cluster_df )
```



La perçu des cinq premières lignes du DataFrame contenant les clusters et leurs coordonnées dans PCA.

Ticker	Cluster	PCA_1	PCA_2
JNJ	1	-8.389	6.170
AMGN	1	9.975	4.806
UNH	1	-20.568	5.627
PG	1	-5.195	-9.636
MRK	1	-6.295	-19.413

Interprétation des résultats PCA

La représentation en composantes principales permet de visualiser la structure latente du cluster 1.

On observe que les actifs du cluster 1 sont relativement proches dans l'espace factoriel, ce qui confirme leur forte similarité comportementale en termes de rendements.

Ces actifs correspondent majoritairement à des valeurs défensives (santé et consommation de base), ce qui explique leur regroupement :

- JNJ, UNH, AMGN, MRK : secteur santé, comportements fortement corrélés
- PG : consommation de base, profil défensif stable

La dispersion sur PCA_1 et PCA_2 reste limitée, ce qui confirme la cohérence interne du cluster et valide la pertinence du regroupement obtenu par l'algorithme de clustering.

Résumé des clusters obtenus

L'algorithme de clustering a permis de regrouper les actifs en 5 clusters distincts selon leur similarité statistique basée sur les rendements.

On observe une forte séparation entre les secteurs défensifs (santé, consommation de base) et les secteurs plus cycliques (technologie, finance, industrie).

Cluster	Actifs
1	JNJ, AMGN, UNH, PG, MRK, MCD, KO
2	WMT
3	VZ
4	CVX, TRV
5	V, AMZN, SHW, AXP, NVDA, NKE, MSFT, BA, MMM, CAT, CRM, JPM, IBM, HON, HD, GS


Cette étape permet de :

- construire une base de données multi-actifs cohérente
- regrouper les actifs selon leur comportement statistique
- préparer la sélection des paires cointégrées

2.1 Analyse des corrélations

Cette étape consiste à calculer la matrice de corrélation entre les différents actifs afin d'identifier les relations linéaires existantes et de préparer la sélection des paires candidates pour la stratégie de pair trading.

```
corr_matrix = returns.corr()
```



Les paires sélectionnées présentent des corrélations élevées, comprises entre 0.60 et 0.75, ce qui indique un comportement fortement synchronisé.

On observe notamment :

- des paires du secteur financier (JPM, GS, AXP) fortement corrélées entre elles
- des géants technologiques (MSFT, AAPL, AMZN, NVDA) avec des dynamiques proches
- une paire défensive (PG - KO) issue du secteur de la consommation de base

Ces résultats confirment que les corrélations élevées sont principalement intra-sectorielles, ce qui constitue une base solide pour la construction de stratégies de pair trading basées sur le retour à la moyenne.

Cluster	Stock A	Stock B	Corrélation
5	JPM	GS	0.749
5	AMZN	MSFT	0.689
5	MSFT	AAPL	0.685
1	PG	KO	0.651
5	AXP	JPM	0.641
5	NVDA	MSFT	0.638
5	AXP	GS	0.624
5	SHW	HD	0.603

2.2 Observation clé

Les secteurs dominent la structure :

- tech très corrélée
- finance très corrélée
- défensif stable

2.3 Test de cointégration

La cointégration est ensuite testée sur les paires les plus corrélées afin de vérifier l'existence d'une relation d'équilibre à long terme entre les actifs.

```
cointegration_df = test_cointegration(  
    pairs_df,  
    prices,  
    PVALUE_THRESHOLD  
)
```

Les paramètres utilisés sont les suivants :

- `pairs_df` : ensemble des paires candidates issues des étapes de corrélation et de clustering
- `prices` : séries de prix historiques des actifs
- `PVALUE_THRESHOLD` : seuil de significativité statistique utilisé pour valider ou rejeter l'hypothèse de cointégration

Cluster	Stock A	Stock B	Corrélation	p-value	Cointégré
5	SHW	HD	0.603	0.016	True
5	AXP	GS	0.624	0.115	False
5	AXP	JPM	0.641	0.251	False
1	PG	KO	0.651	0.424	False
5	JPM	GS	0.749	0.533	False
5	NVDA	MSFT	0.638	0.555	False
5	AMZN	MSFT	0.689	0.592	False
5	MSFT	AAPL	0.685	0.770	False

Les résultats montrent que malgré des corrélations parfois élevées entre certains actifs, très peu de paires sont réellement cointégrées.

Seule la paire SHW–HD présente une p-value inférieure au seuil de 0.05, indiquant une relation stable à long terme.

Les autres paires, bien que corrélées, ne sont pas cointégrées, ce qui confirme que la corrélation seule n'est pas suffisante pour construire une stratégie de pair trading robuste. Ainsi, la cointégration agit comme un filtre statistique permettant de sélectionner uniquement les paires exploitables pour une stratégie de retour à la moyenne.

2.4 Paire retenue

À partir des résultats de cointégration, seules les paires statistiquement significatives sont conservées.

```
best_pairs = select_best_pairs(cointegration_df)
```

Cluster	Stock A	Stock B	Corr.	P-Value	Cointegrated
5	SHW	HD	0.603	0.016	True

Table 4: Paires finales sélectionnées après test de cointégration

On observe qu'une seule paire passe le test de cointégration : **SHW / HD**. Cette paire présente :

- une corrélation positive modérée
- une p-value inférieure au seuil fixé
- une relation statistiquement stable dans le temps

Sélection de la meilleure paire

La meilleure paire issue du test de cointégration est extraite comme suit :


```
best_pair = best_pairs.iloc[0]
stock_a = best_pair["Stock_A"]
stock_b = best_pair["Stock_B"]
plot_best_pair(prices, stock_a, stock_b)
corr = returns[stock_a].corr(returns[stock_b])
pvalue = best_pair["PValue"]
```

Visualisation des prix de la paire sélectionnée

La fonction `plot_best_pair` permet de visualiser l'évolution des prix des deux actifs formant la meilleure paire sélectionnée.

```
plot_best_pair(prices, stock_a, stock_b)
```

Cette figure représente l'évolution conjointe des prix des deux actifs sur la période d'étude, permettant d'observer visuellement leur co-mouvement et de vérifier la pertinence de la paire pour une stratégie de *pair trading*.



Indicateurs de la paire sélectionnée

Les principaux indicateurs statistiques de la paire retenue sont les suivants :

- **Corrélation** : 0.603
- **p-value de cointégration** : 0.0156

Ces résultats indiquent une corrélation modérée entre les deux actifs, ainsi qu'une p-value inférieure au seuil de significativité, confirmant l'existence d'une relation de cointégration exploitable pour une stratégie de pair trading.

2.5 Analyse multi-périodes

Afin de tester la robustesse de la relation de cointégration, l'analyse est répétée sur plusieurs fenêtres temporelles.

```
PERIODS = { "2020_2025": ("2020-01-01", "2025-01-01"),  
            "2021_2025": ("2021-01-01", "2025-01-01"), "2022_2025":  
            ("2022-01-01", "2025-01-01"), "2023_2025": ("2023-01-01",  
            "2025-01-01") }
```


Pour chaque période, la corrélation des rendements et le test de cointégration (Engle-Granger) sont calculés.

```
score, pvalue, _ = coint(prices_period[stock_a],  
prices_period[stock_b])
```

Résultats obtenus

Période	Corrélation	P-value	5%	10%
2020-2025	0.687	0.0136	True	True
2021-2025	0.600	0.0093	True	True
2022-2025	0.603	0.0156	True	True
2023-2025	0.581	0.1254	False	False

Table 5: Stabilité de la cointégration de la paire SHW/HD selon différentes fenêtres temporelles



Interprétation

Les résultats montrent que la paire SHW/HD est globalement cointégrée sur les périodes longues (2020–2025, 2021–2025 et 2022–2025), avec des p-values inférieures aux seuils de significativité.

En revanche, sur la période récente (2023–2025), la p-value dépasse 0.10, indiquant une perte de cointégration.

La relation entre les deux actifs semble se dégrader récemment, suggérant une possible rupture structurelle et une diminution de la robustesse de la stratégie de pair trading.

2.6 Analyse de stationnarité

L'analyse de stationnarité constitue une étape essentielle dans la mise en place d'une stratégie de pair trading. En effet, la plupart des méthodes statistiques utilisées dans ce type de stratégie supposent que les séries étudiées possèdent des propriétés statistiques stables dans le temps.

L'objectif est donc de vérifier :

- si les prix des actions SHW et HD sont stationnaires ;
- si leurs rendements logarithmiques sont stationnaires ;
- si le spread construit entre les deux actifs présente une dynamique de retour à la moyenne.

Pour cela, deux tests complémentaires sont utilisés :

- le test ADF (*Augmented Dickey-Fuller*) ;
- le test KPSS (*Kwiatkowski-Phillips-Schmidt-Shin*).

Le test ADF a pour hypothèse nulle la présence d'une racine unitaire (non-stationnarité), tandis que le test KPSS considère au contraire la stationnarité comme hypothèse nulle. L'utilisation conjointe des deux tests permet ainsi d'obtenir une analyse plus robuste.

Analyse complète de stationnarité :

```
stationarity_results = test_spread_stationarity(  
    prices=prices,  
    stock_a=STOCK_A,  
    stock_b=STOCK_B,  
    alpha=0.05  
)  
rolling_adf = adf_rolling(  
    spread=stationarity_results["Spread"],  
    window=252,  
    alpha=0.05  
)
```

Series	ADF P-Value	KPSS P-Value	Conclusion
SHW (niveau)	0.6916	0.0100	NON-STATIONNAIRE
HD (niveau)	0.5763	0.0100	NON-STATIONNAIRE
SHW ($\Delta\log$)	0.0000	0.1000	STATIONNAIRE
HD ($\Delta\log$)	0.0000	0.1000	STATIONNAIRE
Spread SHW- $\beta \times$ HD	0.0035	0.0402	AMBIGU

Table 6: Résultats des tests de stationnarité

Les résultats montrent que les prix des actions SHW et HD ne sont pas stationnaires en niveau. Les p-values élevées du test ADF et les faibles p-values du test KPSS indiquent la présence d'une tendance et d'une dynamique non stable dans le temps.

En revanche, les rendements logarithmiques des deux actifs deviennent stationnaires après différenciation. Cette propriété est classique dans les séries financières : les prix suivent généralement des processus intégrés d'ordre 1, tandis que leurs variations sont stationnaires.

Afin de construire une stratégie de pair trading, nous nous intéressons ensuite au spread obtenu à partir de la relation :

$$Spread_t = SHW_t - \beta \times HD_t$$

où β représente le hedge ratio estimé par régression OLS.

Le spread présente des résultats plus nuancés :

- le test ADF rejette l'hypothèse de non-stationnarité ;
- le test KPSS rejette également l'hypothèse de stationnarité.

Cette situation indique une dynamique complexe du spread, probablement liée à des périodes alternant stabilité et instabilité.

Cependant, le test de cointégration d'Engle-Granger confirme l'existence d'une relation de long terme entre SHW et HD :

- statistique : -3.7530 ;
- p-value : $0.0156 < 5\%$;
- conclusion : cointégration validée .

Ainsi, malgré une stationnarité imparfaite du spread, la relation de cointégration justifie l'utilisation de cette paire dans une stratégie de pair trading basée sur le retour à la moyenne.

Une analyse ADF glissante sur une fenêtre de 252 jours (environ une année boursière) montre que le spread est stationnaire environ 12.9% du temps.

Cela confirme que la relation entre les deux actifs n'est pas parfaitement stable au cours du temps, ce qui renforce l'intérêt d'utiliser des techniques complémentaires comme le filtrage Machine Learning afin d'améliorer la robustesse de la stratégie.

2.7 Étude du spread SHW / HD

Afin d'analyser la relation entre les actions SHW et HD, les séries de prix sont d'abord normalisées par leur valeur initiale. Cette normalisation permet de comparer l'évolution relative des deux actifs malgré leurs niveaux de prix différents.

Le spread est ensuite défini comme la différence entre les deux séries normalisées :

$$Spread_t = \frac{SHW_t}{SHW_0} - \frac{HD_t}{HD_0}$$

Construction du spread :

```
norm_a = prices["SHW"] / prices["SHW"].iloc[0]
norm_b = prices["HD"] / prices["HD"].iloc[0]
spread = norm_a - norm_b
```

Visualisation du spread :

```
plt.figure(figsize=(14, 6))
plt.plot( spread, label="Spread" )
plt.axhline( spread.mean(), color="red", linestyle="--", label="Mean"
)
plt.title(f"Spread SHW / HD")
plt.xlabel("Date")
plt.ylabel("Spread")
plt.legend()
plt.grid(True)
plt.show()
```




Figure 1: Évolution du spread entre SHW et HD

Le spread représente l'écart relatif entre les deux actions au cours du temps. Lorsque le spread s'éloigne fortement de sa moyenne historique, cela peut indiquer une situation de déséquilibre temporaire entre les deux actifs.

Dans une stratégie de pair trading, l'hypothèse principale est que cet écart finit par revenir vers sa moyenne de long terme (*mean reversion*). Ainsi :

- un spread élevé peut signaler une surévaluation relative de SHW par rapport à HD ;
- un spread faible peut signaler une sous-évaluation relative de SHW par rapport à HD.

La ligne rouge représente la moyenne historique du spread et sert de référence pour détecter les écarts significatifs utilisés dans la génération des signaux de trading.

2.8 Étude du Z-score SHW / HD

Après la construction du spread, celui-ci est standardisé afin de mesurer l'importance des écarts par rapport à sa moyenne historique. Cette standardisation est réalisée à l'aide du Z-score.

Le Z-score est défini par :

$$Z_t = \frac{Spread_t - \mu_{Spread}}{\sigma_{Spread}}$$

où :

- μ_{Spread} représente la moyenne du spread ;
- σ_{Spread} représente l'écart-type du spread.

Le Z-score permet donc de mesurer combien d'écarts-types le spread se situe au-dessus ou en dessous de sa moyenne.

Calcul du Z-score :

```
zscore = (
spread - spread.mean()
) / spread.std()
```

Visualisation du Z-score :

```
plt.figure(figsize=(14, 6))
plt.plot( zscore, label="Z-Score" )
plt.axhline( 2, color="red", linestyle="--", label="+2" )
plt.axhline( -2, color="green", linestyle="--", label="-2" )
plt.axhline( 0, color="black", linestyle="-", label="Mean" )
plt.title(f"Z-Score SHW / HD")
plt.xlabel("Date")
plt.ylabel("Z-Score")
plt.legend()
plt.grid(True)
plt.show()
```

Le Z-score permet d'identifier les situations où le spread s'éloigne fortement de sa moyenne historique.

Dans le cadre du pair trading :




Figure 2: Évolution du Z-score du spread SHW / HD

- lorsque le Z-score dépasse $+2$, le spread est considéré comme anormalement élevé ;
- lorsque le Z-score descend sous -2 , le spread est considéré comme anormalement faible.

Ces seuils servent à générer les signaux de trading :

- $Z > 2$: stratégie SHORT SHW / LONG HD ;
- $Z < -2$: stratégie LONG SHW / SHORT HD.

Le retour progressif du Z-score vers zéro correspond au phénomène de *mean reversion*, qui constitue le principe fondamental de la stratégie.

L'étude du Z-score permet de transformer le spread en un indicateur standardisé facilement interprétable. Cette approche facilite la détection des anomalies de marché et la génération automatique des signaux d'entrée et de sortie dans la stratégie de pair trading.

3 Stratégie de Pair Trading

Cette section présente la construction de la stratégie de pair trading appliquée à la paire SHW / HD.

L'objectif est d'exploiter les écarts temporaires entre deux actifs fortement corrélés et cointégrés afin de mettre en place une stratégie de retour à la moyenne (mean reversion).

3.1 Estimation du hedge ratio par régression OLS

Le hedge ratio est estimé à l'aide d'une régression linéaire OLS :

```
signals, beta, ols_model = generate.trading.signals( prices=prices,
stock_a=STOCK_A, stock_b=STOCK_B, entry_threshold=ENTRY_THRESHOLD,
exit_threshold=EXIT_THRESHOLD )
```

Variable	Coefficient	p-value
Constante	-85.58	0.000
HD	1.165	0.000

Table 7: Résultats simplifiés de la régression OLS

Le hedge ratio obtenu est :1.165

Résultats de la régression OLS

Interprétation

Le coefficient de 1.165 indique qu'il est nécessaire de prendre une position de couverture d'environ 1.17 unités de HD pour chaque unité de SHW.

Le modèle présente un R^2 élevé (0.899), ce qui indique une forte relation linéaire entre les deux actifs.

Le hedge ratio est stable et significatif, ce qui valide la construction du spread pour la stratégie de pair trading.

Le spread est construit à partir du hedge ratio estimé par régression OLS. Il représente l'écart de valorisation entre les deux actifs de la paire.

Afin d'identifier les opportunités de trading, ce spread est standardisé sous forme de Z-score, permettant de détecter les écarts significatifs par rapport à la moyenne historique.

3.2 Analyse du Spread et du Z-score

Construction du spread

Le spread est construit à partir du hedge ratio estimé via la régression OLS. Il représente l'écart entre les deux actifs de la paire SHW / HD.

```
spread = prices[STOCK_A] - beta * prices[STOCK_B]
```

Afin de standardiser ce signal et le rendre comparable dans le temps, on calcule ensuite un Z-score.

```
zscore = (spread - spread.mean()) / spread.std()
```

Aperçu du spread et du Z-score

Le tableau suivant présente un extrait des valeurs obtenues :

Date	Spread	Z-score
2022-01-03	-101.07	-0.97
2022-01-04	-108.73	-1.45
2022-01-05	-102.27	-1.04
2022-01-06	-103.41	-1.11
2022-01-07	-100.65	-0.94

Table 8: Extrait du spread et du Z-score pour la paire SHW / HD

Le graphique ci-dessous permet d'observer l'évolution du spread dans le temps. On cherche ici à détecter un comportement de retour à la moyenne.

Le Z-score permet de normaliser le spread afin d'identifier les anomalies statistiques.

Règle de trading :




Figure 3: Évolution du spread SHW / HD




Figure 4: Z-score avec seuils de trading

- **Signal d'entrée** : lorsque le Z-score dépasse ± 2 , une position est ouverte
- **Signal de sortie** : lorsque le Z-score revient proche de 0, la position est clôturée

Interprétation:

Le Z-score oscille autour de zéro, ce qui confirme l'hypothèse de retour à la moyenne. Cela signifie que les écarts entre SHW et HD sont transitoires et tendent à se corriger.

Cette propriété est essentielle pour une stratégie de pair trading, car elle permet d'exploiter statistiquement les déséquilibres temporaires du marché.

3.3 Génération des signaux de trading

Les signaux de trading sont générés à partir du Z-score du spread. Ils permettent de traduire les écarts statistiques en décisions d'investissement.

Construction des variables de trading

```
signals = generate_trading_signals(    prices=prices,
stock_a=STOCK_A,    stock_b=STOCK_B,    entry_threshold=ENTRY_THRESHOLD,
exit_threshold=EXIT_THRESHOLD )
```

Chaque observation contient les variables suivantes : - prix des actifs - spread - Z-score
- positions simulées - signal de trading

Aperçu des signaux

Le tableau ci-dessous présente un extrait des signaux générés en fin de période :

Date	Spread	Z-score	Pos A	Pos B	Signal
2024-12-03	-93.65	-0.50	0	0	HOLD
2024-12-06	-106.18	-1.29	0	0	HOLD
2024-12-09	-112.12	-1.66	0	0	HOLD
2024-12-12	-104.95	-1.21	0	0	HOLD
2024-12-16	-102.56	-1.06	0	0	HOLD

Table 9: Extrait des signaux de trading pour la paire SHW / HD

Distribution des signaux

La distribution des signaux générés est la suivante :

HOLD 425
EXIT 288
SHORT_SHW_LONG_HD 32
LONG_SHW_SHORT_HD 8

La majorité des observations correspond à des positions *HOLD*, ce qui indique que le marché reste généralement dans une zone d'équilibre.

Les signaux de trading actifs (LONG/SHORT) apparaissent uniquement lorsque le Z-score dépasse les seuils définis, confirmant une stratégie de retour à la moyenne.

La faible fréquence des signaux d'entrée montre que les opportunités de trading sont rares mais statistiquement significatives.

3.4 Backtest de la stratégie

Une fois les signaux de trading générés, nous procédons à l'évaluation de la performance de la stratégie à travers un backtest historique.

```
signals = run_simple_backtest(signals)
```

Visualisation des dernières observations :

Price_A	Price_B	Spread	Z-score	Strategy Return	Cumul. Return
390.96	416.12	-93.65	-0.50	0.00	1.2956
387.75	414.73	-95.25	-0.60	0.00	1.2956
380.99	413.40	-100.45	-0.93	0.00	1.2956
380.71	418.08	-106.18	-1.29	0.00	1.2956
372.30	415.95	-112.12	-1.66	0.00	1.2956

Table 10: Extrait des résultats du backtest

Le graphique de rendement cumulé illustre l'évolution du capital simulé dans le temps. Une tendance haussière indique une stratégie profitable de pair trading basée sur le retour à la moyenne.




Figure 5: Rendement cumulé

```
plot_cumulative_return(signals)
```

Transition : Le spread et le Z-score permettent de générer des positions dynamiques, ce qui conduit à une évolution de la performance cumulée dans le temps.

Performance globale de la stratégie :

```
Total Return = 29.56%
Sharpe Ratio = 1.51
Max Drawdown = -3.5%
```

Metric	Value
Total Return	29.56%
Sharpe Ratio	1.51
Max Drawdown	-3.5%

Table 11: Résumé des performances du backtest

Interprétation :

- Le rendement total de 29.56% indique une stratégie globalement profitable.
- Le Sharpe ratio supérieur à 1 montre une bonne performance ajustée du risque.
- Le drawdown limité (-3.5%) indique une volatilité contrôlée.

Conclusion : Le backtest confirme la pertinence de la stratégie de pair trading basée sur la cointégration et le retour à la moyenne.

4 Coûts de transaction

Dans une stratégie de pair trading, les coûts de transaction jouent un rôle essentiel car la stratégie génère un nombre élevé d'opérations de marché.

Même si une stratégie semble très rentable avant coûts (*gross return*), les performances réelles peuvent être fortement réduites une fois pris en compte :

- les commissions ;
- le bid-ask spread ;
- le slippage ;
- les coûts d'exécution liés aux positions longues et courtes.

L'objectif de cette analyse est donc d'évaluer la robustesse réelle de la stratégie dans des conditions de marché plus réalistes.

Paramètres des coûts de transaction :

Commission : 0.100%

Bid-Ask Spread : 0.050%

Slippage : 0.050%

Coût aller-retour total (4 jambes) : 0.800%

Résultats avec coûts de transaction :

Indicateur	Valeur
Nombre de trades	26
Coût total prélevé	10.40%
Rendement brut	26.41%
Rendement net	16.01%

Table 12: Impact global des coûts de transaction

Analyse de sensibilité aux coûts de transaction :

Coût par trade (%)	Total Return (%)	Sharpe Ratio	Max Drawdown (%)
0.00	26.41	1.508	-3.50
0.05	23.81	1.390	-3.50
0.10	21.21	1.265	-3.50
0.20	16.01	0.990	-3.50
0.30	10.81	0.687	-3.50
0.50	0.41	0.026	-7.98
1.00	-25.59	-1.429	-23.00

Table 13: Sensibilité des performances aux coûts de transaction

Dans notre cas :

- la stratégie effectue 26 trades ;
- le coût total prélevé représente plus de 10% de performance ;

- le rendement passe de 26.41% brut à 16.01% net.

L'analyse de sensibilité montre également que :

- de faibles coûts de transaction restent compatibles avec une stratégie profitable ;
- une augmentation progressive des coûts détériore rapidement le Sharpe Ratio ;
- lorsque les coûts deviennent élevés (exemple : 1%), la stratégie devient non rentable.

On observe également une forte dégradation du drawdown maximal lorsque les coûts augmentent, ce qui traduit une augmentation du risque global de la stratégie.

Cette étape est essentielle car elle permet d'éviter les stratégies artificiellement performantes uniquement dans un environnement théorique sans friction de marché.

L'intégration des coûts de transaction permet ainsi d'obtenir une évaluation plus réaliste et plus robuste de la performance du pair trading.

5 Optimisation des seuils du Z-score

Objectif

La stratégie de pair trading repose sur deux paramètres critiques : le seuil d'entrée (*entry threshold*) et le seuil de sortie (*exit threshold*).

L'objectif de cette étape est d'identifier la combinaison optimale de ces deux paramètres afin de maximiser le Sharpe ratio de la stratégie.

```
optimization_df, best_result = optimize_thresholds(
    prices=prices,
    stock_a=STOCK_A,
    stock_b=STOCK_B
)
```

5.1 Selection de la meilleure stratégie

Après l'évaluation de plusieurs combinaisons de seuils d'entrée et de sortie, la stratégie la plus performante est retenue selon plusieurs critères :

- le rendement total ;
- le Sharpe Ratio ;
- le niveau de drawdown ;
- le nombre de trades générés.

L'objectif est d'identifier la combinaison offrant le meilleur compromis entre rentabilité et maîtrise du risque.

Sélection des meilleurs paramètres :

```

best_signals = best_result["Signals"]
best_entry = best_result["Entry_Threshold"]
best_exit = best_result["Exit_Threshold"]
print("Meilleur seuil d'entrée :", best_entry)
print("Meilleur seuil de sortie :", best_exit)
print("Total Return :", round(best_result["Total_Return"] * 100, 2),
"%")
print("Sharpe Ratio :", round(best_result["Sharpe_Ratio"], 2))
print("Max Drawdown :", round(best_result["Max_Drawdown"] * 100, 2),
"%")
print("Nombre de trades :", int(best_result["Number_of_Trades"]))

```

Résultats de la meilleure stratégie :

Indicateur	Valeur
Seuil d'entrée optimal	1.0
Seuil de sortie optimal	0.75
Total Return	82.78%
Sharpe Ratio	1.50
Max Drawdown	-10.0%
Nombre de trades	22

Table 14: Performance de la meilleure stratégie de pair trading

Les résultats montrent qu'un seuil d'entrée relativement faible ($Z = 1.0$) permet de détecter davantage d'opportunités de retour à la moyenne.

Le seuil de sortie fixé à 0.75 permet quant à lui de clôturer les positions avant un retour complet à la moyenne, ce qui réduit le risque de retournement du spread.

La stratégie sélectionnée présente :

- un rendement élevé de 82.78% ;
- un Sharpe Ratio supérieur à 1, indiquant une bonne performance ajustée du risque ;
- un drawdown maîtrisé malgré plusieurs phases de volatilité ;
- un nombre limité de trades, ce qui réduit les coûts de transaction.

Cette phase d'optimisation permet d'identifier les paramètres les plus adaptés au comportement historique du spread SHW / HD.

5.2 Backtest optimisé

5.3 Backtest de la stratégie optimisée

La stratégie est ensuite évaluée en utilisant les seuils optimisés d'entrée et de sortie, afin d'analyser son comportement réel sur les données historiques.

Visualisation du backtest optimisé :

```

plot_optimized_backtest(
    best_signals=best_signals,
    stock_a=STOCK_A,
    stock_b=STOCK_B,
    best_entry=best_entry,
    best_exit=best_exit
)

```




Figure 6: Backtest de la stratégie optimisée avec seuils d'entrée et de sortie

Le graphique permet de visualiser l'impact des seuils optimisés sur la génération des signaux de trading.

On observe que :

- les positions ne sont ouvertes que lorsque le Z-score dépasse le seuil d'entrée ;
- les positions sont clôturées dès que le Z-score revient sous le seuil de sortie ;
- cette logique améliore la discipline de la stratégie et réduit les faux signaux.

5.4 Analyse du Z-score optimisé et sauvegarde des résultats

L'optimisation des seuils de la stratégie de pair trading permet de comparer différentes règles de déclenchement des positions. L'objectif est d'identifier la configuration offrant le meilleur compromis entre rentabilité et risque.

Visualisation du Z-score avec seuils optimisés

```

plot_optimized_zscore(
    best_signals=best_signals,
    stock_a=STOCK_A,
    stock_b=STOCK_B,
    best_entry=best_entry,
    best_exit=best_exit
)

```




Figure 7: Z-score optimisé avec seuils d'entrée et de sortie

L'analyse des seuils montre que leur choix influence directement la dynamique de trading :

- un seuil d'entrée faible augmente la fréquence des trades, mais peut générer davantage de faux signaux ;
- un seuil d'entrée élevé réduit le nombre de trades, mais sélectionne uniquement les déséquilibres les plus extrêmes du spread ;
- le seuil de sortie permet de définir le moment optimal de clôture des positions et donc de sécuriser les gains.

Le couple optimal *entry/exit* est sélectionné ici sur la base du Sharpe Ratio, ce qui permet de privilégier une performance ajustée du risque plutôt qu'un simple rendement brut.

Cette étape finalise l'optimisation de la stratégie en sélectionnant les paramètres les plus performants tout en assurant une traçabilité des résultats via leur exportation.

6 Benchmark : Pair Trading vs Buy & Hold

6.1 Objectif

Afin d'évaluer la valeur ajoutée de la stratégie de pair trading, nous la comparons à deux stratégies passives de référence : l'achat et la détention (*Buy & Hold*) de chacun des deux actifs de la paire sur la même période.

```
benchmark_df = build_benchmark_df(  
    prices, best_signals, STOCK_A, STOCK_B  
)  
performance = compute_strategy_performance(benchmark_df)
```

6.2 Résultats

Stratégie	Return	Volatilité	Sharpe	Max Drawdown
Pair Trading	82.78%	14.18%	1.50	-10.00%
Buy & Hold SHW	3.06%	27.94%	0.18	-40.25%
Buy & Hold HD	2.76%	24.90%	0.16	-34.20%

Table 15: Comparaison des performances : Pair Trading vs Buy & Hold (2022–2025)




Figure 8: Évolution du rendement cumulé : Pair Trading vs Buy & Hold

6.3 Analyse des résultats

Les résultats montrent une nette supériorité de la stratégie de pair trading sur les deux stratégies passives, sur l'ensemble des métriques :

- **Rendement total** : le pair trading génère 82.78% contre moins de 3.1% pour les stratégies Buy & Hold, soit un écart de plus de 79 points de pourcentage

- **Volatilité** : la stratégie pair trading présente une volatilité annualisée de 14.18%, soit presque deux fois inférieure à celle de SHW (27.94%) et HD (24.90%), confirmant son caractère market-neutral
- **Sharpe ratio** : le pair trading atteint 1.50 contre 0.18 et 0.16 pour les Buy & Hold, indiquant un rendement ajusté du risque largement supérieur
- **Max Drawdown** : le pair trading limite les pertes maximales à -10%, contre -40.25% pour SHW et -34.20% pour HD, ce qui témoigne d'une bien meilleure résistance aux chocs de marché

6.4 Nuance méthodologique

Cette comparaison doit être interprétée avec précaution car les deux approches n'ont pas le même profil de risque :

- le **Buy & Hold** est une stratégie directionnelle, exposée à la tendance générale du marché — elle bénéficie des phases haussières mais subit pleinement les corrections
- le **Pair Trading** est une stratégie market-neutral, dont les gains proviennent uniquement de la convergence du spread, indépendamment de la direction du marché

Le Sharpe ratio permet néanmoins une comparaison sur une base risque-ajustée en normalisant le rendement par la volatilité totale :

$$\text{Sharpe} = \frac{E[R]}{\sigma(R)} \times \sqrt{252}$$

Cependant, le Sharpe ratio suppose implicitement une distribution normale des rendements. Or les stratégies long/short présentent fréquemment des distributions asymétriques avec des queues épaisses, ce qui peut conduire à une surestimation de la performance ajustée du risque.

Une métrique plus adaptée serait le **Sortino ratio**, qui ne pénalise que la volatilité négative (downside deviation) :

$$\text{Sortino} = \frac{E[R]}{\sigma_{\text{down}}(R)} \times \sqrt{252}$$

Cette distinction constitue une limite méthodologique de la comparaison présentée ici, et pourrait faire l'objet d'une amélioration future du pipeline.

6.5 Conclusion

La stratégie de pair trading démontre une capacité à générer un alpha significatif par rapport aux stratégies passives, tout en maintenant une volatilité et un drawdown bien inférieurs.

Ces résultats confirment l'intérêt d'une approche statistique et market-neutral pour exploiter les inefficiences temporaires entre actifs cointégrés.

7 Prédiction de Convergence (Machine Learning Classifieur)

Afin d'améliorer la stratégie de pair trading, nous introduisons un modèle de Machine Learning visant à prédire la probabilité de retour du spread vers sa moyenne le jour suivant.

L'objectif est de transformer les signaux statistiques (spread, Z-score, variations récentes) en un signal prédictif exploitable pour affiner les décisions d'entrée et de sortie.

Le dataset est construit à partir des signaux de trading précédents, en ajoutant des variables retardées et des transformations du spread.

```
classifier_result = train_classifier(signals)
classifier_result["ML_DF"].head()
```

Date	Spread	Z-score	Position A	Position B	Signal	Strategy Ret.	Cum. Ret.	Target
2022-01-05	-102.27	-1.04	0	0	HOLD	0.00	1.0000	0
2022-01-06	-103.41	-1.11	0	0	HOLD	0.00	1.0000	1
2022-01-07	-100.65	-0.94	0	0	HOLD	0.00	1.0000	1
2022-01-10	-94.14	-0.53	0	0	HOLD	0.00	1.0000	1
2022-01-11	-92.16	-0.41	0	0	EXIT	0.00	1.0000	0

Table 16: Extrait du dataset utilisé pour le modèle de Machine Learning

Description des variables :

- Spread et Z-score actuels,
- valeurs retardées (lags),
- variations du spread,
- rendements retardés,
- variable cible indiquant la convergence du spread.

Le spread reste globalement stationnaire autour de sa moyenne, avec un Z-score proche de zéro.

Les signaux de trading sont principalement neutres, ce qui indique peu d'opportunités fortes sur cette période.

Le signal EXIT apparaît lors du retour à l'équilibre, confirmant la logique de mean reversion.

La variable cible montre que le modèle ML capture partiellement ces dynamiques de convergence.

Nous évaluons la performance du classifieur Random Forest sur la prédiction de convergence du spread.

```
print("Accuracy :", classifier_result["Accuracy"])
print(classifier_result["Classification Report"])
```

Résultats obtenus : Accuracy = 53%

Classe	Precision	Recall	F1-score	Support
0	0.55	0.28	0.37	93
1	0.52	0.78	0.63	95
Accuracy	0.53			
Macro avg	0.54	0.53	0.50	188
Weighted avg	0.54	0.53	0.50	188

Table 17: Rapport de classification du modèle Random Forest

```
print( classifier_result["Classification_Report"])
```

- La classe 0 (absence de convergence) est mal détectée avec un recall de 28%, ce qui signifie que le modèle identifie difficilement les périodes sans retour à la moyenne.
- La classe 1 (convergence du spread) est mieux captée avec un recall de 78%, indiquant que le modèle tend à prédire plus facilement les phases de mean reversion.
- La précision reste proche de 0.5 pour les deux classes, ce qui traduit une forte incertitude dans les prédictions.

Feature	Importance
Spread_Change	0.173964
Spread	0.168305
Zscore	0.161390
Spread_Lag1	0.146592
Return_B_Lag1	0.126625
Zscore_Lag1	0.120439
Return_A_Lag1	0.102685

Table 18: Importance des variables dans le modèle Random Forest

L'analyse des variables permet d'identifier les facteurs les plus influents dans la prédiction.

```
feature_importance = classifier_result["Feature_Importance"]
feature_importance
```

Cette visualisation permet de mettre en évidence les facteurs explicatifs dominants de la dynamique de *mean reversion*.

```
plt.figure(figsize=(10,5))
plt.bar( feature_importance["Feature"], feature_importance["Importance"]
)
plt.title("Importance des variables - Random Forest")
plt.xticks(rotation=45) plt.grid(True)
plt.show()
```





Figure 9: Random Forest

Le modèle Random Forest présente une performance modérée mais supérieure au hasard.

Cela indique que la dynamique de mean reversion est partiellement prédictible à partir des variables de marché, mais reste fortement bruitée.

Ainsi, l'intégration d'un modèle de Machine Learning peut améliorer la stratégie de pair trading, sans toutefois garantir une capacité prédictive forte à elle seule.

8 Prédiction du rendement à J+1 par régression

8.1 Objectif

Contrairement au modèle de classification présenté en section 7, qui prédit la *direction* de la convergence du spread, cette étape vise à prédire la **valeur exacte** du rendement de la stratégie le jour suivant (J+1).

```
regressor_result = train_regressor(best_signals)
```

8.2 Méthodologie

Le modèle utilisé est un **Random Forest Regressor** (300 arbres, max_depth=4), entraîné sur les mêmes features que le classifier :

- Zscore, Zscore_Lag1
- Spread, Spread_Lag1, Spread_Change
- Return_A_Lag1, Return_B_Lag1

La variable cible est le rendement réel de la stratégie au jour suivant :

$$\text{Target}_t = \text{Strategy_Return}_{t+1}$$

L'échantillon est divisé en ensemble d'entraînement (75%) et de test (25%), sans mélange aléatoire afin de respecter l'ordre chronologique des données.

8.3 Résultats

Métrique	Valeur
MAE	0.004253
RMSE	0.008071
R^2	-0.0906

Table 19: Métriques de performance du modèle de régression

Le tableau ci-dessous présente un extrait des rendements réels et prédits sur l'échantillon de test :

Date	Rendement réel J+1	Rendement prédit J+1
2024-04-03	0.000000	0.000093
2024-04-04	0.000000	0.002278
2024-04-05	0.000000	0.000134
2024-04-08	0.000000	0.001881
2024-04-09	-0.000000	0.000006
2024-04-10	-0.000000	0.000056
2024-04-11	-0.000000	0.000275
2024-04-12	-0.000959	0.002599
2024-04-15	0.008631	0.004268
2024-04-16	-0.011745	0.003618

Table 20: Comparaison des rendements réels et prédits à J+1




Figure 10: Rendements réels vs prédits à J+1

8.4 Interprétation

Les résultats révèlent les limites inhérentes à la prédiction de rendements financiers futurs :

- le **R² négatif** (-0.09) indique que le modèle est moins performant que de prédire simplement la moyenne des rendements — ce qui est un résultat classique en finance, où les rendements futurs sont quasi-imprévisibles à court terme
- le **MAE** de 0.0043 et le **RMSE** de 0.0081 restent faibles en valeur absolue, mais ils sont élevés relativement aux rendements journaliers de la stratégie, qui sont eux-mêmes très proches de zéro la plupart du temps
- l'extrait du tableau montre que le modèle prédit systématiquement des valeurs positives et proches de zéro, alors que les rendements réels alternent entre valeurs nulles, positives et négatives — le modèle ne capture pas la dynamique réelle des rendements

8.5 Pourquoi ce résultat est attendu

La difficulté de prédire les rendements futurs s'explique par plusieurs facteurs structurels :

- les rendements financiers sont **proches du bruit blanc** — leur autocorrélation est quasi nulle à court terme
- la stratégie de pair trading génère majoritairement des rendements nuls (position HOLD), ce qui rend la variable cible très déséquilibrée
- les features utilisées (Z-score, spread, lags) capturent bien la dynamique de *mean reversion* pour la classification, mais sont insuffisantes pour prédire l'amplitude exacte du mouvement futur

8.6 Utilité dans le pipeline

Malgré ses faibles performances prédictives, le régresseur conserve une utilité dans le pipeline : sa prédiction est intégrée comme feature dans le **méta-modèle** (section 10), où elle contribue — conjointement aux autres signaux — à la décision finale.

Le signal reste faible mais potentiellement informatif lorsqu'il est combiné avec d'autres sources d'information.

9 Modèle de Machine Learning sans Data Leakage

Cette section présente une version plus robuste du modèle de Machine Learning appliqué à la stratégie de pair trading, en supprimant toute fuite d'information (*data leakage*).

Dans les séries temporelles financières, le data leakage apparaît lorsqu'une information future est utilisée implicitement pendant l'entraînement du modèle. Cela conduit à des performances artificiellement élevées et non reproductibles en conditions réelles de marché.

Afin d'éviter ce problème, une séparation temporelle stricte des données a été mise en place :

- les observations passées sont utilisées pour l'entraînement ;
- les observations futures sont réservées au test hors échantillon ;
- la normalisation est réalisée uniquement sur les données d'entraînement ;
- les variables explicatives sont construites uniquement à partir des informations disponibles à la date t .

9.1 Entraînement du classifieur sans fuite d'information

Le modèle de classification est entraîné à l'aide d'un split temporel strict.

```
classifier_result_NL = train_classifier_no_leakage(  
    signals=signals,  
    test_size=0.2,  
    n_splits_cv=5  
)
```

Le modèle utilise :

- un ensemble d'entraînement représentant 80% des données ;
- un ensemble de test hors échantillon représentant 20% ;
- une validation croisée temporelle (*Time Series Cross Validation*).

9.2 Split temporel

Le découpage chronologique obtenu est le suivant :

Ensemble	Période	Observations
Train	2022-01-18 → 2024-05-28	593
Test	2024-05-29 → 2024-12-30	149

Table 21: Split temporel du modèle sans leakage

La vérification anti-leakage retourne :

Vérification anti-leakage : OK

Fold	Accuracy
Fold 1	0.4796
Fold 2	0.5204
Fold 3	0.5000
Fold 4	0.5816
Fold 5	0.5306

Table 22: Validation croisée temporelle

9.3 Validation croisée temporelle

Une validation croisée adaptée aux séries temporelles est réalisée afin d'évaluer la stabilité du modèle.

L'accuracy moyenne obtenue est :

$$0.5224 \pm 0.0344$$

Les performances restent relativement stables d'un fold à l'autre, ce qui indique une certaine robustesse du modèle.

9.4 Performance du classifieur

Les performances du modèle sont évaluées sur les données hors échantillon.

Métrique	Valeur
Accuracy OOS	0.5101
Accuracy IN-sample	1.0000

Table 23: Performance du classifieur sans leakage

L'écart important entre l'accuracy in-sample et hors échantillon met en évidence un phénomène de surapprentissage (*overfitting*).

9.5 Rapport de classification

Classe	Precision	Recall	F1-score
0	0.49	0.47	0.48
1	0.53	0.55	0.54

Table 24: Rapport de classification hors échantillon

Les résultats montrent des performances relativement équilibrées entre les deux classes, bien que le pouvoir prédictif reste limité.

9.6 Importance des variables

Le tableau suivant présente les variables les plus importantes pour le modèle.

Variable	Importance
Zscore	0.1198
Return_A_MA5	0.1157
Zscore.Std10	0.1142
Spread_Diff2	0.1122
Zscore_Lag2	0.1115
Zscore_Lag3	0.1101
Return_B_MA5	0.1093
Spread_Diff1	0.1093
Zscore_Lag1	0.0979

Table 25: Importance des variables du modèle

Le Z-score et ses retards (*lags*) apparaissent comme les variables les plus influentes, ce qui confirme l'importance du comportement de retour à la moyenne dans la dynamique du spread.

9.7 Régression sans fuite d'information

Un modèle de régression est également entraîné afin de prédire le rendement futur du spread.

```
regressor_result_NL = train_regressor_no_leakage(
    signals=signals,
    test_size=0.2
)
```

Les résultats obtenus sont les suivants :

Métrique	Valeur
MAE (OOS)	0.000894
RMSE (OOS)	0.003070
R^2 OOS	-1.3091
R^2 IN-sample	0.8301

Table 26: Performance du régresseur sans leakage

Le coefficient R^2 négatif hors échantillon montre que le modèle ne généralise pas correctement sur les données futures.

Ce résultat confirme la difficulté de prédire précisément les rendements financiers et souligne l'importance d'une méthodologie rigoureuse sans fuite d'information.

9.8 Interprétation

La suppression du data leakage réduit fortement les performances apparentes du modèle par rapport aux versions précédentes.

Cependant, cette approche fournit une estimation beaucoup plus réaliste des capacités prédictives exploitables en conditions réelles de marché.

Cette étape est essentielle dans un projet de finance quantitative, car elle permet d'éviter des conclusions biaisées et des stratégies non reproductibles en pratique.

10 XGBoost Classification

Cette section introduit un modèle de gradient boosting, XGBoost, comme alternative au Random Forest afin d'évaluer l'impact du choix d'algorithme sur la prédiction de convergence du spread.

XGBoost (*eXtreme Gradient Boosting*) est un algorithme d'ensemble particulièrement populaire en finance quantitative pour sa capacité à capturer des relations non linéaires complexes sur des données tabulaires, tout en offrant de bonnes performances en termes de vitesse et de régularisation.

10.1 Entraînement du modèle XGBoost

Le modèle est entraîné sur les mêmes features que le Random Forest, à partir des signaux de la stratégie de pair trading :

```
xgb_result = train_xgboost_classifier(  
    signals  
)
```

Les hyperparamètres utilisés sont les suivants :

- `n_estimators` = 300 ;
- `max_depth` = 4 ;
- `learning_rate` = 0.05 ;
- `subsample` = 0.8 ;
- `colsample_bytree` = 0.8.

10.2 Performances du modèle

L'accuracy obtenue sur le jeu de test est de **57,4%**.

Le rapport de classification détaillé est le suivant :

Classe	Precision	Recall	F1-score	Support
0 (Divergence)	0.59	0.47	0.52	93
1 (Convergence)	0.57	0.67	0.62	95
Macro avg	0.58	0.57	0.57	188
Weighted avg	0.58	0.57	0.57	188

Table 27: Rapport de classification — XGBoost

Le modèle présente une légère asymétrie en faveur de la classe 1 (convergence), avec un recall de 67%, ce qui est cohérent avec l'objectif de la stratégie : détecter les épisodes de convergence du spread.

Feature	Importance
Spread	0.162
Return_B_Lag1	0.153
Spread_Lag1	0.145
Zscore	0.139
Zscore_Lag1	0.137
Spread_Change	0.133
Return_A_Lag1	0.132

Table 28: Importance des features — XGBoost

10.3 Importance des variables

L'importance des features est relativement équilibrée entre les différentes variables, ce qui reflète la nature complémentaire des signaux utilisés :

Contrairement au Random Forest, où le z-score domine généralement, XGBoost distribue l'importance de manière plus homogène, suggérant qu'il exploite davantage les interactions entre variables.

10.4 Comparaison Random Forest vs XGBoost

Les deux modèles sont comparés sur la même tâche de classification :

Modèle	Accuracy
Random Forest	53.2%
XGBoost	57.4%

Table 29: Comparaison des accuracies — Random Forest vs XGBoost

XGBoost surpasse le Random Forest de **4,2 points de pourcentage**, ce qui confirme l'intérêt du gradient boosting pour ce type de prédiction sur données financières tabulaires.

Il convient néanmoins de nuancer ce résultat : une accuracy de 57% reste modeste, et les deux modèles sont entraînés sans séparation temporelle stricte. La section 9 présente une version corrigée sans data leakage, qui constitue la référence méthodologiquement rigoureuse.

11 Deep Learning — LSTM

Cette section introduit un modèle de deep learning de type LSTM (*Long Short-Term Memory*) appliqué à la stratégie de pair trading.

Contrairement aux modèles Random Forest ou XGBoost, qui traitent chaque observation de manière indépendante, le LSTM apprend directement à partir de séquences temporelles. Il exploite les dépendances entre les observations successives de z-score, de spread et de rendements passés pour effectuer ses prédictions.

11.1 LSTM Classifieur

11.1.1 Architecture et paramètres

Le modèle est entraîné pour prédire si le spread va converger le lendemain, à partir des 20 derniers jours d'observations :

```
lstm_result = train_lstm_classifier(  
    signals=signals,  
    sequence_length=20,  
    test_size=0.2,  
    epochs=50,  
    batch_size=16  
)
```

Les features utilisées en entrée du LSTM sont :

- Zscore ;
- Spread ;
- Return_A ;
- Return_B.

L'architecture du réseau comprend une couche LSTM avec 32 unités cachées, suivie d'une couche de dropout (0.2), puis d'un bloc fully connected ($32 \rightarrow 16 \rightarrow 1$) avec activation ReLU et une sortie sigmoïde via `BCEWithLogitsLoss`.

11.1.2 Courbe d'apprentissage

La loss d'entraînement (*Binary Cross-Entropy*) décroît progressivement sur les 50 epochs, de 0.70 à 0.58, confirmant que le modèle converge correctement. On observe quelques oscillations autour des epochs 25 et 40, typiques des réseaux récurrents entraînés sur des séries financières bruitées.

11.1.3 Performances

L'accuracy obtenue sur le jeu de test est de **51,0%**.

Classe	Precision	Recall	F1-score	Support
0 (Divergence)	0.50	0.44	0.47	72
1 (Convergence)	0.52	0.57	0.54	75
Macro avg	0.51	0.51	0.51	147
Weighted avg	0.51	0.51	0.51	147

Table 30: Rapport de classification — LSTM Classifieur

La probabilité de convergence estimée sur la dernière observation disponible est de **49,0%**, ce qui correspond à un signal neutre (proche du seuil de décision à 50%).

11.1.4 Probabilités de convergence prédites

La figure suivante représente l'évolution de la probabilité de convergence estimée par le LSTM sur la période de test (juin 2024 – décembre 2024). On observe une forte variabilité du signal, avec des alternances rapides entre des probabilités élevées (≥ 0.8) et très faibles (≤ 0.1), ce qui reflète la difficulté du modèle à stabiliser ses prédictions sur cette période.

11.2 LSTM Régresseur

11.2.1 Objectif

Cette variante utilise un LSTM Régresseur pour prédire le **rendement futur de la stratégie à horizon $J+1$** , plutôt qu'une classe binaire. Elle constitue le pendant deep learning du Random Forest Régresseur présenté en section 8.

```
lstm_reg_result = train_lstm_regressor(  
    signals=signals,  
    sequence_length=5,  
    test_size=0.2,  
    epochs=10,  
    batch_size=64,  
    hidden_size=8  
)
```

11.2.2 Convergence de l'entraînement

La loss MSE décroît rapidement sur les 10 epochs, passant de 0.0187 à 0.0003, ce qui indique une bonne convergence sur les données d'entraînement :

Epoch	Loss (MSE)
1	0.018708
2	0.008133
3	0.002431
4	0.000590
5	0.000587
6	0.000490
7	0.000357
8	0.000343
9	0.000311
10	0.000286

Table 31: Courbe de loss — LSTM Régresseur

11.2.3 Performances

Les métriques obtenues sur le jeu de test sont les suivantes :

Le coefficient de détermination $R^2 = -45.17$ est très largement négatif, ce qui indique que le modèle est moins performant qu'une prédiction naïve par la moyenne.

Métrique	Valeur
MAE	0.010240
RMSE	0.013680
R^2	-45.17

Table 32: Métriques de régression OOS — LSTM Régresseur

11.2.4 Prédictions vs rendements réels

La figure ci-dessous illustre clairement le problème : le modèle prédit des rendements systématiquement positifs et d’amplitude bien supérieure aux rendements réels, qui sont quasi nuls sur la majeure partie de la période de test. Le LSTM a visiblement sur-appris les quelques pics de rendement présents en août–septembre 2024, sans parvenir à généraliser.




Figure 11: LSTM Régresseur — Rendement prédit J+1 vs rendement réel

Ce résultat s’explique par plusieurs facteurs :

- les rendements journaliers d’une stratégie de pair trading sont très proches de zéro et extrêmement bruités ;
- une séquence de seulement 5 jours est insuffisante pour capturer des dynamiques temporelles significatives ;
- le volume de données disponible (environ 750 observations) est nettement insuffisant pour entraîner un réseau récurrent de manière robuste.

La prédiction sur la dernière observation disponible est de **+0.28%**, à interpréter avec prudence compte tenu des métriques OOS.

11.3 Synthèse

Le LSTM obtient les performances les plus faibles sur les deux tâches. Ce résultat n’est pas surprenant : les modèles de deep learning nécessitent généralement des volumes de données bien supérieurs à ceux disponibles ici. Sur des données financières tabulaires de faible volume, les modèles ensemblistes tels que XGBoost restent souvent supérieurs.

Modèle	Tâche	Performance
Random Forest	Classification	Accuracy = 53.2%
XGBoost	Classification	Accuracy = 57.4%
LSTM	Classification	Accuracy = 51.0%
Random Forest	Régression	$R^2 > 0$
LSTM	Régression	$R^2 = -45.17$

Table 33: Comparaison des modèles — Classification et Régression

12 Analyse de Sentiment NLP

Cette section présente l'intégration d'une couche d'analyse de sentiment basée sur le traitement du langage naturel (NLP) appliquée aux actualités financières des deux actifs de la paire **SHW** / **HD**.

L'objectif est d'enrichir le pipeline quantitatif avec une information qualitative issue du contexte de marché, afin d'ajouter un biais directionnel complémentaire aux signaux statistiques et ML.

12.1 Principe de l'analyse lexicale

L'analyse repose sur une approche lexicale simple : chaque titre de news est scanné et un score est attribué selon la présence de mots positifs ou négatifs prédéfinis.

```

POSITIVE_WORDS = [
    "strong", "growth", "expands", "positive",
    "beat", "higher", "demand", "margin"
]

NEGATIVE_WORDS = [
    "weak", "pressure", "cautious", "decline",
    "lower", "risk", "inflation", "faces"
]
```

Pour chaque titre, le score de sentiment est calculé comme suit :

$$\text{Sentiment Score} = \sum_{w \in \text{titre}} \mathbf{1}[w \in \text{Positifs}] - \sum_{w \in \text{titre}} \mathbf{1}[w \in \text{Négatifs}]$$

Le score final par action correspond à la moyenne des scores obtenus sur l'ensemble de ses titres.

12.2 Données utilisées

Les news utilisées dans ce pipeline sont des données simulées représentatives d'actualités financières typiques pour chaque actif :

Ticker	Titre
SHW	"Sherwin-Williams reports strong demand in housing renovation"
SHW	"Sherwin-Williams expands margins despite inflation"
HD	"Home Depot faces pressure from weaker consumer spending"
HD	"Home Depot announces cautious outlook"

```
news_data, sentiment_by_stock = compute_sentiment()
```

12.3 Résultats obtenus

Ticker	Sentiment Score moyen
SHW	+1.5
HD	-1.5

Table 34: Scores de sentiment moyens par actif

La différence de sentiment entre les deux actifs est :

$$\Delta\text{Sentiment} = \text{Score}_{SHW} - \text{Score}_{HD} = 1.5 - (-1.5) = +3.0$$

12.4 Interprétation et utilisation dans le pipeline

Le score différentiel positif ($\Delta = +3.0$) indique que SHW bénéficie d'un contexte fondamental plus favorable que HD au moment de l'analyse.

Ce signal est ensuite intégré dans deux composants du pipeline :

- **Aggregation layer** (`aggregation.py`) : le sentiment contribue directement à la recommandation finale en renforçant ou atténuant les signaux statistiques
- **Meta-model** (`meta_model.py`) : la différence de sentiment est utilisée comme feature dans le modèle de régression logistique final

Concrètement, un $\Delta\text{Sentiment} > 0$ renforce un signal **LONG SHW / SHORT HD**, en cohérence avec un Z-score négatif (SHW sous-valorisé par rapport à HD).

12.5 Limites de l'approche

Cette implémentation constitue une preuve de concept. Plusieurs limitations doivent être notées :

- les news sont **simulées** et non issues d'un flux de données réel (Reuters, Bloomberg, etc.)
- le lexique est volontairement restreint (8 mots positifs, 8 mots négatifs) sans pondération sémantique
- aucune dimension temporelle n'est prise en compte (toutes les news ont le même poids quelle que soit leur date)
- une approche plus avancée pourrait intégrer des modèles de type *FinBERT* ou *VADER* pour une analyse contextuelle plus fine

Malgré ces simplifications, l'intégration du sentiment apporte un contexte qualitatif complémentaire aux signaux purement quantitatifs, enrichissant ainsi la robustesse de la décision finale.

13 Filtre Machine Learning

Après l'optimisation des seuils de trading, un filtre basé sur le Machine Learning est ajouté afin d'améliorer la qualité des signaux générés par la stratégie de pair trading.

L'objectif de ce filtre est de conserver uniquement les positions pour lesquelles le modèle estime une probabilité suffisamment élevée de convergence du spread. Cette approche permet de réduire les faux signaux et d'éviter certaines positions peu favorables.

Le filtre repose sur les probabilités prédites par le modèle Random Forest :

```
ml_filtered_signals = apply_ml_filter(  
signals=best_signals,  
classifier_result=classifier_result,  
stock_a=STOCK_A,  
stock_b=STOCK_B,  
entry_threshold=best_entry,  
proba_threshold=0.55  
)
```

Le paramètre `proba_threshold = 0.55` signifie que seuls les signaux dont la probabilité prédite de convergence dépasse 55% sont conservés.

Extrait des signaux filtrés :

Date	Z-score	Probabilité	Pos A	Pos B	Signal	Cum. Return
2024-12-24	-1.177	0.522	0	0	HOLD	2.4087
2024-12-26	-1.169	0.541	0	0	HOLD	2.4087
2024-12-27	-1.146	0.481	0	0	HOLD	2.4087
2024-12-30	-1.184	0.511	0	0	HOLD	2.4087
2024-12-31	-1.080	NaN	0	0	HOLD	2.4087

Table 35: Extrait des signaux après application du filtre Machine Learning

Interprétation :

Le filtre Machine Learning agit comme une couche supplémentaire de validation des signaux de trading. Même lorsque le Z-score indique une opportunité potentielle de retour à la moyenne, la position n'est prise que si le modèle estime que la probabilité de convergence est suffisamment élevée.

Cette approche permet :

- de réduire le nombre de faux signaux ;
- d'améliorer la robustesse de la stratégie ;
- de limiter certaines positions prises dans des phases de marché défavorables ;
- d'introduire une dimension prédictive complémentaire à la logique statistique classique du pair trading.

Le Machine Learning ne remplace donc pas la stratégie de pair trading, mais agit comme un filtre intelligent permettant de sélectionner les signaux les plus pertinents.

13.1 Comparaison : stratégie brute vs stratégie filtrée par Machine Learning

Afin d'évaluer l'apport du filtre Machine Learning, nous comparons la performance de la stratégie de pair trading classique (basée uniquement sur le Z-score) avec la stratégie filtrée par le modèle prédictif.

Le filtre ML permet de sélectionner uniquement les signaux pour lesquels la probabilité de convergence du spread est jugée suffisamment élevée, ce qui vise à améliorer le ratio rendement/risque de la stratégie.

```
plot_ml_filtered_strategy(  
    best_signals=best_signals,  
    ml_filtered_signals=ml_filtered_signals  
)
```




Figure 12: Comparaison des performances : stratégie brute vs stratégie filtrée par ML

13.2 Performance de la stratégie filtrée par Machine Learning

Après application du filtre Machine Learning, nous évaluons la performance de la stratégie afin de mesurer l'impact de la sélection des signaux sur les résultats globaux.

```
ml_metrics = compute_ml_filtered_performance(ml_filtered_signals)
```

Résultats obtenus :

```
ML Filtered Total Return = 140.87%  
ML Filtered Sharpe Ratio = 3.22  
ML Filtered Max Drawdown = -4.45%
```

Interprétation :

L'application du filtre Machine Learning améliore significativement les performances de la stratégie de pair trading.

Metric	Value
Total Return	140.87%
Sharpe Ratio	3.22
Max Drawdown	-4.45%

Table 36: Performance de la stratégie filtrée par Machine Learning

On observe tout d’abord une augmentation importante du rendement total (140.87%), ce qui indique que la sélection des signaux a permis de se concentrer sur les opportunités les plus rentables.

Le Sharpe ratio supérieur à 3 traduit une amélioration très nette du couple rendement/risque, suggérant que les trades pris après filtrage sont globalement plus efficaces et mieux optimisés.

Par ailleurs, le drawdown maximal reste limité (-4.45%), ce qui montre que cette amélioration de performance ne s’accompagne pas d’une augmentation excessive du risque.

Le filtre Machine Learning agit comme un véritable mécanisme de sélection des signaux de qualité. Il permet d’améliorer à la fois la rentabilité et la stabilité de la stratégie, confirmant l’intérêt d’une approche hybride combinant méthodes statistiques (cointégration, Z-score) et modèles prédictifs.

13.3 Comparaison des résultats

Afin de comparer l’impact du filtre Machine Learning sur la performance globale de la stratégie, nous synthétisons les principaux indicateurs de performance pour la stratégie optimisée et la stratégie filtrée.

```
summary_results = build_summary_results(
    best_result=best_result,
    ml_metrics=ml_metrics,
    ml_filtered_signals=ml_filtered_signals
)
```

Résumé des performances :

Strategy	Total Return (%)	Sharpe Ratio	Max Drawdown (%)	Nb Trades
Pair Trading Optimisé	82.78	1.50	-10.00	22
Pair Trading + ML Filter	140.87	3.22	-4.45	61

Table 37: Comparaison des performances des différentes stratégies

La stratégie filtrée par Machine Learning présente des performances nettement supérieures à la stratégie de pair trading classique.

Elle permet d’augmenter significativement le rendement total tout en améliorant le profil de risque, comme en témoigne la hausse du Sharpe ratio et la réduction du drawdown maximal.

Cependant, cette amélioration s’accompagne d’une augmentation du nombre de trades, ce qui reflète une stratégie plus active et plus sélective dans la prise de position.

En effet, le filtre ML agit comme un mécanisme de sélection des opportunités, en ne conservant que les signaux pour lesquels la probabilité de convergence du spread est

jugée suffisamment élevée. Cela permet de réduire les faux signaux, mais peut également entraîner l'omission de certaines opportunités potentiellement profitables.

14 Méta-Modèle

Cette section construit un méta-modèle chargé de combiner les différents signaux produits par le pipeline quantitatif :

- le signal de pair trading (z-score) ;
- la probabilité de convergence estimée par le classifieur ML ;
- la prédiction de rendement issue du modèle de régression ;
- le score de sentiment NLP.

Plutôt que de pondérer ces signaux de manière arbitraire, le méta-modèle — une régression logistique — apprend automatiquement la combinaison optimale afin de prédire si le rendement futur de la stratégie sera positif. Il constitue la couche de décision finale du pipeline.

14.1 Entraînement

```
meta_result = train_meta_model(  
    signals=signals,  
    classifier_result=classifier_result,  
    regressor_result=regressor_result,  
    sentiment_by_stock=sentiment_by_stock,  
    stock_a=STOCK_A,  
    stock_b=STOCK_B,  
    best_entry=best_entry,  
    proba_threshold=0.55  
)
```

Les quatre features d'entrée du méta-modèle sont construites comme suit :

- **Pair_Score** : vaut +1 si le z-score est inférieur au seuil d'entrée négatif (signal long), -1 s'il dépasse le seuil positif (signal short), et 0 sinon ;
- **ML_Convergence_Prob** : probabilité de convergence estimée par le Random Forest classifieur ;
- **Reg_Prediction** : rendement à J+1 prédit par le Random Forest régresseur ;
- **Sentiment_Score** : différence de sentiment entre SHW et HD, issue de l'analyse NLP.

14.2 Performance du méta-modèle

L'accuracy obtenue sur le jeu de test est de **100%**.

Ce résultat est à interpréter avec la plus grande prudence. Une accuracy de 100% sur un jeu de test financier constitue un signal d'alarme fort, et non une performance réaliste. Plusieurs causes peuvent l'expliquer :

Classe	Precision	Recall	F1-score	Support
0 (Rendement négatif)	1.00	1.00	1.00	47
Accuracy		1.00		47

Table 38: Rapport de classification — Méta-modèle

- le jeu de test ne contient que **47 observations**, ce qui est insuffisant pour évaluer la généralisation du modèle ;
- la cible (*rendement positif à $J+1$*) est fortement déséquilibrée sur cette période, avec une seule classe présente dans le rapport de classification ;
- certains des signaux d'entrée (notamment `Reg_Prediction`) peuvent contenir des informations implicitement corrélées à la cible, introduisant un risque résiduel de data leakage.

En conditions réelles de marché, ces performances ne sauraient être reproduites.

14.3 Probabilité et recommandation finale

La probabilité de rendement positif estimée par le méta-modèle sur la dernière observation disponible est de **0,43%**, bien en dessous du seuil de décision fixé à 55%. La recommandation finale est donc :

Recommandation : HOLD

14.4 Tableau de décision final

L'ensemble des signaux contributeurs à la décision finale est récapitulé dans le tableau suivant :

Métrique	Valeur
Latest Z-score	-1.080
Best Entry Threshold	1.0
Pair Score	+1
ML Convergence Probability	0.511
Predicted Strategy Return J+1	0.000019
Sentiment SHW	+1.5
Sentiment HD	-2.0
Sentiment Difference	+3.5
Sentiment Score	+1
Meta Model Accuracy	1.00
Meta Model Probability Positive Return	0.004
Decision Threshold	0.55
Final Recommendation	HOLD

Table 39: Tableau de décision final — Méta-modèle

Le z-score de -1.08 est en dessous du seuil d'entrée en valeur absolue, ce qui génère un `Pair_Score` de $+1$ (légèrement en zone long), mais insuffisant pour déclencher un

signal. Le sentiment est favorable à SHW par rapport à HD (différence de +3.5), mais la probabilité finale du méta-modèle reste trop faible pour franchir le seuil de décision.

14.5 Coefficients du méta-modèle

Les coefficients de la régression logistique permettent d'identifier l'influence relative de chaque signal dans la décision finale :

Feature	Coefficient
Pair_Score	-1.664
ML_Convergence_Prob	+0.166
Reg_Prediction	+0.073
Sentiment_Score	+0.000

Table 40: Coefficients de la régression logistique — Méta-modèle




Figure 13: Coefficients du méta-modèle (régression logistique)

Plusieurs observations ressortent de l'analyse des coefficients :

- **Pair_Score** domine avec un coefficient très négatif (-1.664). Ce résultat peut sembler contre-intuitif, mais s'explique par le fait qu'un signal long (z-score négatif) est associé, sur la période d'entraînement, à des rendements futurs négatifs plutôt que positifs ;
- **ML_Convergence_Prob** contribue positivement ($+0.166$), confirmant l'utilité du classifieur comme filtre de qualité du signal ;
- **Reg_Prediction** apporte une contribution marginalement positive ($+0.073$) ;

- **Sentiment_Score** a un coefficient quasi nul (+0.000), ce qui reflète la faible granularité de l'analyse de sentiment réalisée ici, basée sur une liste de mots-clés et un nombre très limité d'articles.

14.6 Synthèse

Le méta-modèle constitue une approche élégante pour agréger des signaux hétérogènes au sein d'un pipeline quantitatif. Il présente l'avantage d'apprendre automatiquement les poids de chaque composant, là où une approche ad hoc nécessiterait une calibration manuelle.

Cependant, les résultats obtenus ici sont à nuancer fortement : l'accuracy de 100% est un artefact lié à la faible taille du jeu de test et au déséquilibre des classes. Pour une utilisation en conditions réelles, il conviendrait d'augmenter significativement le volume de données, d'appliquer un split temporel strict (cf. section 9), et d'enrichir l'analyse de sentiment avec des sources de données plus complètes.

15 Conclusion générale

Ce projet a permis de concevoir, d'implémenter et d'évaluer un pipeline quantitatif complet de *Pair Trading* appliqué à la paire d'actifs **SHW / HD**. En partant d'une approche purement statistique basée sur la cointégration, le modèle a progressivement été enrichi par des briques de Machine Learning, de Deep Learning et d'analyse de sentiment (NLP).

15.1 Synthèse des Résultats Économiques et Modélisations

L'évaluation des différentes étapes de l'architecture met en évidence plusieurs enseignements fondamentaux :

- **La stratégie classique et l'impact des coûts** : La stratégie initiale de retour à la moyenne basée sur le Z-score démontre une capacité robuste à générer des profits en conditions idéales. Néanmoins, l'introduction réaliste de coûts de transaction (frais de courtage et *slippage*) pèse significativement sur la rentabilité, rendant l'optimisation fine des seuils d'entrée et de sortie indispensable pour préserver l'alpha.
- **L'apport et les limites du Machine Learning isolé** : Les modèles prédictifs individuels comme le classifieur **XGBoost** et le réseau de neurones récurrent **LSTM** affichent des performances hors-échantillon modestes (des taux d'exactitude oscillant autour de 52% à 54%). Ces résultats illustrent la complexité inhérente et la faiblesse du ratio signal/bruit sur les marchés financiers. De même, l'analyse de sentiment NLP par mots-clés a montré une contribution marginale en raison d'un volume de données textuelles restreint.
- **La puissance de l'approche hybride par Méta-Modèle** : L'innovation majeure réside dans l'intégration finale au sein d'un méta-modèle d'agrégation. En apprenant de manière pondérée les probabilités de convergence de chaque sous-modèle, cette couche décisionnelle agit comme un filtre puissant contre les faux signaux. Elle permet de rejeter les positions initiées lors de divergences structurelles prolongées du spread, réduisant ainsi le *Maximum Drawdown* global.

15.2 Perspectives d'Amélioration

Bien que le pipeline actuel démontre la pertinence d'une architecture hybride, plusieurs axes d'amélioration peuvent être envisagés pour une transition vers un environnement de production réel :

1. **Enrichissement des données textuelles (NLP)** : Remplacer l'approche par dictionnaire de mots-clés par un modèle de langage avancé (de type BERT financier ou LLM) connecté à un flux d'actualités en temps réel (*Reuters*, *Bloomberg*) afin d'obtenir des scores de sentiment à plus haute granularité.
2. **Expansion du gisement d'actifs** : Étendre l'algorithme de clustering (ACP et K-Means) à l'ensemble d'un indice (comme le S&P 500) pour identifier et surveiller simultanément un portefeuille de dizaines de paires cointégrées, diversifiant ainsi le risque de modèle.
3. **Modélisation dynamique du Hedge Ratio** : Remplacer la régression OLS statique par un filtre de Kalman (*Kalman Filter*) pour permettre un ajustement dynamique et en temps réel du ratio de couverture face aux changements de régimes de marché.

En conclusion, ce travail démontre qu'en finance quantitative, la valeur ajoutée du Machine Learning ne réside pas nécessairement dans la prédiction directionnelle brute à haute exactitude, mais plutôt dans sa capacité à agir comme un filtre de gestion des risques rigoureux, optimisant la prise de décision au sommet d'une stratégie statistique robuste.